

DATA SCIENCE

NLP

&

Deep Learning

 **DANIEL KRESISCH**

Contenido

Problema de negocio



Objetivo general



Origen de datos



EDA



Limpieza de texto



Tokenización



Remover Stopwords



Lematización



Palabras más frecuentes



Nubes de palabras



N-Gramas



Machine Learning



Deep Learning



Conclusión final



Líneas futuras



Herramientas



Descripción del Problema de negocio

La empresa *Opinia*, dedicada al comercio electrónico y la oferta de servicios digitales, recibe miles de reseñas de usuarios cada mes.

Estas opiniones reflejan la experiencia de los clientes con los productos, los tiempos de entrega, la atención postventa y la calidad del servicio.

Hasta el momento, el análisis de estas reseñas se realizaba de forma manual o con métricas básicas (como el promedio de estrellas), lo cual resulta insuficiente para comprender el sentimiento real detrás de los comentarios.


La falta de un sistema inteligente limita la capacidad de la empresa para identificar áreas de mejora, anticipar insatisfacciones y evaluar de forma precisa la satisfacción del cliente.

Por ello, *Opinia* enfrenta el desafío de transformar texto no estructurado en conocimiento accionable, aplicando técnicas de **Procesamiento del Lenguaje Natural (NLP)** combinadas con modelos de **Machine Learning y Deep Learning**.

El objetivo es crear una solución automatizada capaz de interpretar el tono emocional de las reseñas y ofrecer información valiosa para la toma de decisiones estratégicas.



Objetivo general



El objetivo principal de este proyecto es desarrollar un sistema integral de **análisis de sentimientos** que clasifique las reseñas de los clientes según su valoración y contenido textual, utilizando modelos de **aprendizaje automático y redes neuronales**.


Para lograrlo, se implementa un pipeline completo de **Procesamiento del Lenguaje Natural (NLP)** que incluye limpieza de texto, tokenización, eliminación de stopwords, lematización, vectorización mediante TF-IDF y el entrenamiento de modelos predictivos.

En particular, se emplean dos enfoques complementarios:

- **Regresión Logística (Machine Learning)** con representaciones TF-IDF.
- **Red Neuronal MLP (Deep Learning)** utilizando secuencias de texto .

El sistema permitirá a *Opinia*:

- Analizar automáticamente el sentimiento y la satisfacción de los clientes.
- Detectar patrones lingüísticos asociados a opiniones positivas o negativas.
- Obtener métricas cuantitativas para monitorear la calidad del servicio.
- Mejorar la toma de decisiones basada en datos y retroalimentación real de usuarios.




Origen de datos

El conjunto de datos es sintético, generado por ChatGPT y está compuesto por dos variables principales:


- **Text:** contiene las opiniones de los clientes.
- **Rating:** representa la puntuación que los usuarios otorgaron a Opinia, en una escala del 1 al 5.

En total, el dataset cuenta con 2.350 registros, una cantidad adecuada para desarrollar este proyecto de Data Science.

EDA – Análisis exploratorio de datos



El gráfico permite visualizar la frecuencia de cada nivel de calificación. La mayoría de las reseñas se concentran en valores altos del rating, indicando una tendencia hacia opiniones positivas.



El gráfico permite observar la relación entre el rating y la longitud de las reseñas. Se comprobó que, a medida que aumenta la calificación, las reseñas tienden a ser más breves; en cambio, cuando la puntuación es baja, los comentarios suelen ser más extensos y detallados.

Limpieza de texto

En esta etapa se va eliminar elementos que pueden dificultar el análisis, como mayúsculas, tildes, números, signos de puntuación y espacios extras. El objetivo es dejar únicamente las letras en un formato uniforme que los algoritmos puedan procesar de manera más eficiente.

Ejemplo antes y después:

	text	clean_text_limpio
0	Nada especial, aunque el precio fue justo.	nada especial aunque el precio fue justo
1	Superó mis expectativas totalmente.	supero mis expectativas totalmente
2	Buen producto y excelente presentación. buen	buen producto y excelente presentacion buen
3	Producto aceptable pero esperaba más.	producto aceptable pero esperaba mas
4	Buen producto y excelente presentación.	buen producto y excelente presentacion

Tokenización

¿Qué es?

La **tokenización** es el proceso de dividir un texto en unidades más pequeñas llamadas "tokens" (generalmente palabras o subpalabras).

Ejemplo:

- Texto: "El lenguaje natural es fascinante"
- Tokens: ["El", "lenguaje", "natural", "es", "fascinante"]

¿Para qué sirve?

Es un paso fundamental en NLP porque:

- Los modelos no entienden texto crudo: Necesitan convertir las palabras en números, y la tokenización es el primer paso.
- Define las unidades básicas de análisis: Establece qué constituye una "palabra" o unidad de significado en el texto.
- Facilita el procesamiento: Permite aplicar técnicas como embeddings, eliminación de palabras irrelevantes y análisis sintáctico.

En resumen, la tokenización traduce el texto humano a un formato que las máquinas pueden procesar y analizar.

Ejemplo antes y después de tokenización:

	text	clean_text_limpio
0	Nada especial, aunque el precio fue justo.	[Nada, especial, ,, aunque, el, precio, fue, j...
1	Superó mis expectativas totalmente.	[Superó, mis, expectativas, totalmente, .]
2	Buen producto y excelente presentación. buen	[Buen, producto, y, excelente, presentación,
3	Producto aceptable pero esperaba más.	[Producto, aceptable, pero, esperaba, más, .]
4	Buen producto y excelente presentación.	[Buen, producto, y, excelente, presentación, .]

Remove stopwords

¿Qué es?

Stopwords son palabras muy comunes que aportan poco significado al análisis de texto, como artículos, preposiciones y conjunciones. Removerlas significa eliminarlas del texto antes de procesarlo.

Ejemplo:

- Texto original: "El gato está en la casa"
- Sin stopwords: ["gato", "casa"]
- Stopwords removidas: "El", "está", "en", "la"

Ejemplo antes y después de remover stopwords:

	text	clean_text_limpio
0	Nada especial, aunque el precio fue justo.	especial, aunque precio justo.
1	Superó mis expectativas totalmente.	Superó expectativas totalmente.
2	Buen producto y excelente presentación. buen	Buen producto excelente presentación. buen
3	Producto aceptable pero esperaba más.	Producto aceptable esperaba más.
4	Buen producto y excelente presentación.	Buen producto excelente presentación.

¿Para qué sirve?

Remove stopwords puede ser útil porque:

- **Reduce el ruido:** Elimina palabras que no contribuyen al significado principal del texto.
- **Disminuye la dimensionalidad:** Reduce el tamaño del vocabulario, haciendo el procesamiento más eficiente.
- **Optimiza recursos:** Menos palabras significa menor tiempo de procesamiento y uso de memoria.

Lematización

¿Qué es?

La **lematización** es el proceso de reducir las palabras a su forma base o raíz llamada "lema" (la forma que aparecería en un diccionario).

Ejemplo:

- "corriendo", "corrió", "correr" → "**correr**"
- "mejor", "bueno", "buenos" → "**bueno**"
- "soy", "eres", "fue" → "**ser**"

Ejemplo antes y después de la lematización:

	text	clean_text_limpio
0	Nada especial, aunque el precio fue justo.	especial precio justo
1	Superó mis expectativas totalmente.	superar expectativa totalmente
2	Buen producto y excelente presentación. buen	producto excelente presentación
3	Producto aceptable pero esperaba más.	Producto aceptable esperar
4	Buen producto y excelente presentación.	producto excelente presentación


¿Para qué sirve?

La lematización es útil porque:


- **Normaliza variaciones:**
agrupa distintas formas de una palabra bajo un mismo concepto.
- **Simplifica el vocabulario:**
reduce palabras únicas sin perder significado.
- **Mejora el análisis:** reconoce "amar", "ama" y "amaba" como la misma idea.

En resumen, la lematización unifica las distintas formas gramaticales de una palabra en su versión básica, facilitando el análisis y reduciendo la complejidad del vocabulario.

Palabras más frecuentes



En este gráfico se observan las palabras más relevantes del conjunto de datos después del proceso de limpieza.




En este gráfico se observan las palabras antes de la limpieza, donde aparecen términos menos significativos.

Nubes de palabras

En esta sección crearemos nubes de palabras para identificar visualmente los términos más utilizados en las reseñas. Además, generaremos nubes separadas para comentarios positivos y negativos, lo que nos permitirá comparar el vocabulario característico de cada tipo de opinión.



Reseñas positivas




Reseñas negativas



N-Gramas

Un n-grama es simplemente una secuencia de palabras consecutivas. Analizaremos combinaciones de 2 y 3 palabras juntas (por ejemplo: "muy bueno", "producto muy bueno") para identificar las frases que más se repiten. De esta forma capturamos el contexto completo, no solo palabras aisladas.



Machine Learning




En esta etapa se implementó un modelo de Machine Learning para clasificar las reseñas según su valoración, utilizando la técnica TF-IDF (con uni- y bi-gramas) como vectorización de texto y una Regresión Logística como clasificador. Este enfoque busca medir la capacidad del modelo para identificar correctamente el tono de las opiniones a partir de un conjunto de datos más amplio y realista, representando un punto de referencia sólido antes de aplicar métodos de Deep Learning.


Accuracy (Regresión Logística): 0.927

Reporte de clasificación:

	precision	recall	f1-score	support
1.0	0.955	0.913	0.933	46
2.0	0.932	0.972	0.952	71
3.0	0.976	0.892	0.933	93
4.0	0.893	0.885	0.889	122
5.0	0.916	0.970	0.942	135
accuracy			0.927	467
macro avg	0.934	0.927	0.930	467
weighted avg	0.928	0.927	0.927	467


El modelo logró un desempeño destacado (accuracy del 92,9%), mostrando una gran precisión en las valoraciones positivas y un comportamiento equilibrado en las clases intermedias. Los errores observados se concentran entre calificaciones vecinas, lo cual resulta natural en textos con matices de opinión. En conjunto, la Regresión Logística demostró ser una herramienta confiable y eficiente para el análisis de sentimiento en lenguaje natural, ofreciendo resultados interpretables y consistentes.






Deep Learning

En esta sección se desarrolló un modelo de Deep Learning utilizando una arquitectura MLP (Multilayer Perceptron) junto con el enfoque Text to Sequence de Keras. A partir de los textos limpios y tokenizados, cada reseña se transformó en una secuencia numérica que alimentó una red con capas densas y dropout para evitar sobreajuste. El objetivo fue comparar el rendimiento de esta red neuronal frente al modelo clásico de Regresión Logística implementado previamente.



El modelo alcanzó un accuracy del 92,9%, mostrando un desempeño muy similar al del enfoque de Machine Learning, aunque con una ligera mejora en la estabilidad de las predicciones. La red neuronal logró aprender patrones más complejos del lenguaje y generalizó bien en el conjunto de validación, manteniendo un equilibrio entre precisión y recall. Estos resultados confirman la efectividad del enfoque secuencial y establecen una base sólida para explorar arquitecturas más avanzadas en futuros trabajos.



Accuracy (MLP): 0.929

Reporte de clasificación:

	precision	recall	f1-score	support
1.0	0.956	0.935	0.945	46
2.0	0.920	0.972	0.945	71
3.0	0.976	0.892	0.933	93
4.0	0.908	0.885	0.896	122
5.0	0.916	0.970	0.942	135
accuracy			0.929	467
macro avg	0.935	0.931	0.932	467
weighted avg	0.930	0.929	0.929	467

Conclusión final

El análisis de las reseñas de la empresa Opinía permitió comprender mejor la percepción de los clientes sobre la calidad de los productos y la atención brindada.

Durante el proceso se aplicaron técnicas de procesamiento de lenguaje natural (NLP) como tokenización, limpieza, eliminación de stopwords y lematización, logrando transformar el texto en información estructurada y útil para el modelado.

En la etapa predictiva, tanto el modelo de Regresión Logística con TF-IDF como la red neuronal MLP mostraron un desempeño sólido, alcanzando niveles de exactitud cercanos al 93%. Esto evidencia que el preprocesamiento adecuado y la correcta representación vectorial del texto son factores clave para el éxito del análisis. Estos resultados demuestran la viabilidad de aplicar modelos de aprendizaje automático y profundo en entornos reales para monitorear la satisfacción del cliente y detectar áreas de mejora en productos o servicios.



Líneas futuras

En base a los resultados obtenidos, existen múltiples oportunidades para continuar y fortalecer este proyecto:

- **Incorporar modelos de lenguaje más avanzados:** utilizar representaciones contextuales como Word2Vec, GloVe o transformadores tipo BETO (BERT entrenado para español), que permitirían captar mejor el significado y la intención detrás de las opiniones.
- **Analizar datos en tiempo real:** implementar un flujo de datos que procese nuevas reseñas automáticamente y actualice métricas de satisfacción en dashboards o reportes ejecutivos.
- **Ampliar el alcance del análisis:** adaptar el modelo a otros idiomas o plataformas (redes sociales, encuestas, soporte técnico), generando una herramienta multicanal de monitoreo del sentimiento del cliente.

Estas mejoras permitirían transformar este proyecto en una solución escalable y aplicable en entornos empresariales reales, capaz de detectar tendencias, anticipar problemas y mejorar la experiencia del usuario de forma continua.



Herramientas



Python



ChatGPT



Microsoft Excel




Github



Canva

Link de GitHub: <https://github.com/danykre/Opinia>



¡GRACIAS!



danielkresisch.com.ar



danielkresisch@gmail.com



[linkedin.com/in/daniel-kresisch/](https://www.linkedin.com/in/daniel-kresisch/)



github.com/danykre